

Si può migliorare un agente cambiando solo il prompt?

Sei versioni di un agente di assistenza clienti, stesso modello e stessi 50 task, misurate contro l'agente di default del benchmark. L'ultima lo batte di dodici punti — ma la parte che vale non è il punteggio: è *perché* falliva, e come lo si dimostra.

68%

agente di default

80,5%

nostro agente, media di 4 giri


90%

tetto raggiungibile misurato

50 task del dominio airline, un'esecuzione per versione. Il punteggio è binario: un task riesce solo se lo stato finale del database coincide con quello atteso e le informazioni richieste sono state comunicate al cliente.

Sei versioni, e cinque strade sbagliate

Ogni versione nasce dalla lettura dei fallimenti della precedente. La v1 raccoglie le regole emerse dalla prima tassonomia; v2 e v3 provano a isolarne l'effetto; v4 ristruttura l'intero prompt; v5 e v6 correggono difetti trovati leggendo le tracce. Per cinque versioni il guadagno resta dentro il rumore: solo l'ultima, ripetuta quattro volte, lo supera davvero.



Il tetto non è teorico: è la quota di task risolti da almeno una delle sei versioni. I cinque che non passa nessuno sono analizzati a pagina 5.

Tre modi diversi di sbagliare

Il punteggio binario dice solo «fallito». Leggendo le conversazioni una per una, i fallimenti si separano in tre famiglie con cause distinte — e due di esse erano invisibili finché non abbiamo guardato *quali azioni* l'agente aveva davvero eseguito.

A • Non agisce

Il cliente dice «sì» e chiude la chiamata prima che l'azione parta.

3

task

comunica bene, non esegue

B • Agisce troppo

Si scrive da solo una giustificazione falsa e la usa come autorizzazione.

2

task

esegue ciò che è vietato

C • Sceglie male

Cerca il «più economico» e si ferma al primo risultato valido.

4

task

mai affrontata fino alla v5

La famiglia C è la scoperta più scomoda: è la più numerosa, e per cinque versioni non le avevamo dedicato una sola riga di prompt.

Esempio reale (famiglia B): l'agente scrive «nessun segmento è stato ancora volato» due righe sotto le date dei voli, che sono nel passato — e procede a cancellare una prenotazione che la policy protegge.

Il confronto completo

Ogni versione contro l'agente di default, sugli stessi task. «Vinti» e «persi» contano i task che cambiano esito. Il valore p viene dal test di McNemar: solo la v6, ripetuta quattro volte, arriva a **una differenza statisticamente significativa**.

VERSIONE	RIUSCITI	TASSO	VINTI	PERSI	P	COSTO/SUCCESSO
default	34/50	68%	—	—	—	\$0,0449
v1 · le prime regole	39/50	78%	+6	−1	0,125	\$0,0435
v2 · due clausole	38/50	76%	+6	−2	0,289	\$0,0464
v3 · una clausola	35/50	70%	+4	−3	1,000	\$0,0475
v4 · ristrutturazione	37/50	74%	+5	−2	0,453	\$0,0568
v5 · conferma unica	38/50	76%	+6	−2	0,289	\$0,0534
v6 · quattro esecuzioni	—	80,5%	+9	−0	0,004	\$0,0507

La riga della v6 è la media di quattro esecuzioni complete (200 simulazioni); vinti, persi e p sono quelli della migliore. Le altre righe vengono da **una sola** esecuzione: non sono numeri della stessa attendibilità.

Il costo conta quanto il punteggio

Criterio fissato prima di misurare: costo totale diviso i task riusciti. La v4 costa il 31% in più della v1 e ne risolve meno — la ristrutturazione non si ripaga.

Il rumore è più grande dell'effetto

Lo stesso agente, girato quattro volte sugli stessi task, oscilla fra 74% e 86%. Le differenze fra le versioni a esecuzione singola stanno dentro quel margine.

Cinque task che non passa nessuno

Sopra il 90% non arriva nessuna versione. Analizzandoli uno per uno, la maggior parte non è colpa dell'agente: sono difetti del benchmark che abbiamo documentato, o problemi che richiedono capacità che il modello non ha.

2 · risultato atteso
incoerente col task

2 · bug nel confronto
del database

2 · oltre il modello
ricerca e aritmetica

1 · bug dell'hash
passa 1 volta su 4

Quattro dei cinque sono difetti del benchmark, non nostri. Due task chiedono uno stato finale che nessuna lettura difendibile della policy produce. Altri due colpiscono un bug nel confronto fra database: l'esito viene giudicato sbagliato solo perché una lista è in ordine diverso. La segnalazione è stata inviata agli autori.

E il limite del modello, misurato invece che supposto

Ordinando le 70 submission pubbliche della classifica ufficiale per punteggio su questo dominio, **nessuna sopra l'80% è stata ottenuta senza ragionamento**: chi ci arriva usa un modello con thinking nativo o un secondo modello che rivede le azioni. Il confronto più vicino al nostro — stessa famiglia di modello, ma con ragionamento attivo — fa 82,5%.

Non è una scusa per ciò che resta fuori: è un limite documentato con una fonte pubblica e verificabile.

Ogni numero è ispezionabile

Tutte le esecuzioni finiscono in un unico dataset su Langfuse: sei versioni, gli stessi 50 task, affiancate riga per riga. Per ogni task si legge la conversazione completa — cliente, agente, chiamate agli strumenti — accanto al risultato atteso e ai punteggi.

Confronto affiancato

Ogni versione contro il default sullo stesso task, con la differenza di punteggio evidenziata.

Dialogo integrale

La conversazione turno per turno, comprese le chiamate agli strumenti e i loro risultati.

Metriche per azione

Non solo riuscito/fallito: azioni non richieste, argomenti sbagliati, quota di azioni corrette.

Cosa resta

I quattro giri richiesti dallo standard di Sierra sono completi. I risultati sono pubblicati nello stesso dataset delle versioni precedenti: dieci esecuzioni sugli stessi cinquanta task, confrontabili riga per riga.

Codice dell'agente, modifiche al benchmark e diario completo del percorso — incluse le ipotesi sbagliate — sono pubblici nel repository del progetto.